※ Generative model Basic

- GAN :

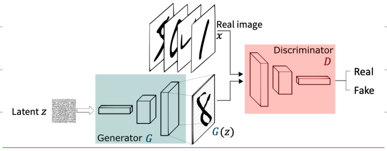

- loss → Generator loss + Discriminator loss
- 한계 : mode collapse / non-convergence
  - ↳ discriminator가 너무 잘 작동

- VAE :

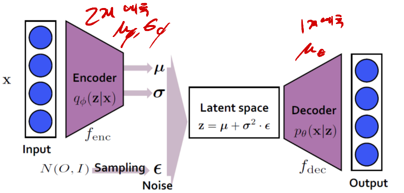

→ encoder는 μ, σ 예측

- goal: $p(x)$ 구하기

$$p(x) = \int p(x,z)\,dz$$

$$\rightarrow \log p(x) = \log \int p(x,z)\,dz$$

$$= \log \int p(x,z) \cdot \frac{q_\phi(z|x)}{q_\phi(z|x)}\,dz$$

$$= \log E_{z\sim q_\phi}\left[\frac{p(x,z)}{q_\phi(z|x)}\right]$$

$$\xrightarrow[\text{ELBO}]{\text{Concave}} \;\geq\; E_{z\sim q_\phi}\left[\log \frac{p(x,z)}{q_\phi(z|x)}\right]$$

$$= \underbrace{E_{z\sim q_\phi(z|x)}\left[\log p(x|z)\right]}_{\text{Maximize}} - \underbrace{D_{KL}\left(q_\phi(z|x)\,\|\,p(z)\right)}_{\text{minimize}}$$

- 학습 단계 ; 1. encoder 에서 μ_ϕ 와 σ_ϕ 예측
  2. decoder 에 z 주입 ($z = \mu_\phi + \sigma_\phi \epsilon$)
  3. decoder 에서 μ_θ 예측
  4. back props

$N(0, I)$

- 학습 방법 ; $\underset{\theta,\phi}{\operatorname{argmax}} \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}\left(q_\phi(z|x) \,\|\, p(z)\right)$
  1. $\frac{1}{N} \sum \log p_\theta(x|z)$, 단 $z \sim q_\phi(x|z)$
  2. 이때 $p_\theta(x|z) = N(D_\theta(z), \sigma^2 I)$ (μ_θ)
  3. $\log p_\theta(x|z) \approx -\frac{1}{2\sigma^2} \| x - D_\theta(z) \|^2$

- 한계 1. 가정 $p(z) \sim N(0, I)$ 인거.
  2. $\log p(x)$ 의 최대가 아닌, ELBO의 최대를 쓰고있음.

※ DDPM

- loss 중 denoising term : $D_{KL}(q(x_{t-1}|x_t) \| p_\theta(x_{t-1}|x_t))$

$$q(x_{t-1}|x_t, x_0) = q(x_t|x_{t-1}, x_0) \frac{q(x_{t-1}|x_0)}{q(x_t|x_0)}$$

모두 forward process로 결정됨 (Gaussian)

$$\Rightarrow q(x_{t-1}|x_t) \sim N(\tilde{\mu}(x_t, t), \tilde{\sigma}_t^2 I)$$

그로 $D_{KL}(q(x_{t-1}|x_t) \| p_\theta(x_{t-1}|x_t)) \approx \frac{1}{2\sigma^2} \| \mu_p - \mu_q \|^2 + \text{const}$

기본 꼴 : mean predictor

- 변환

$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon$ 에서 $x_0 = \frac{1}{\sqrt{\bar{\alpha}_t}}(x_t - \sqrt{1-\bar{\alpha}_t}\, \epsilon)$

이때 $\tilde{\mu}(x_t, x_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0$ and $\tilde{\sigma}_t^2 = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t.$

그로 $\tilde{\mu}(x_t, \epsilon_t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \epsilon_t\right)$

- 생성 flow :
  1. loss에서 중요한 부분은 $D_{KL}(q(x_{t-1}|x_t) \| p_\theta(x_{t-1}|x_t))$
  2. p_θ, q는 모두 가우시안인데, 두 가우시안의 KL divergence는 다음과 같음 $\frac{1}{2}\left(\frac{\|\mu_1-\mu_2\|^2}{\sigma_2^2} + d\left(\frac{\sigma_1^2}{\sigma_2^2} - 1 - \ln\frac{\sigma_1^2}{\sigma_2^2}\right)\right)$
  3. 그런데 μ만 network 이고, $\sigma_{1,2}$는 const이므로 μ 끼리의 RMSE 꼴로 나타남
  4. $\tilde{\mu}(x_t, x_0) = \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} x_0$ and $\tilde{\sigma}_t^2 = \frac{1-\bar{\alpha}_{t-1}}{1-\bar{\alpha}_t}\beta_t$.
     이 식과 $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon_t$ 를 통해 RMSE loss를 μ_θ, ϵ_θ, x_{0_θ} 로 만들 수 있음

- Train
  1. timestep t를 뽑고, $\epsilon_t \sim N(0, I)$ 뽑기
  2. $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon_t$ 로 x_t 생성
  3. $\|\hat{\epsilon}_\theta(x_t, t) - \epsilon_t\|^2$ 구하고 backprops.
     ↳ timestep $0 \to t$ 의 noise임.

- Inf
  1. $\hat{\epsilon}_\theta(x_t, t)$를 통해 μ_t 예측
     $\rightarrow \mu_\theta(x_t, t) = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\hat{\epsilon}_\theta(x_t, t)\right)$
     noisy input
  2. $x_{t-1} = \mu_t + \sigma z$, $z \sim N(0, I)$
     ↳ $p_\theta(x_{t-1}|x_t)$ 의 μ임!!

* Score matching

- $\nabla_x \log p(x)$; 어느 방향으로 가야 $p(x)$가 커지는지
  $\doteq$ score of $p(x)$

- Score of $q(x_t|x_0) \doteq \nabla_x \log q(x_t|x_0)$
  $x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon_t$ 이므로 $x_t \sim N(\sqrt{\bar{\alpha}_t}\, x_0, (1-\bar{\alpha}_t)I)$
  $\Rightarrow$ 직접 q를 Gaussian form으로 나타내고 미분

$$\nabla_x \log q(x_t|x_0) = -\frac{1}{\sqrt{1-\bar{\alpha}_t}}\epsilon_t$$

즉 ϵ_t를 예측하는 것은 score of $q(x_t|x_0)$를 예측하는 것과 동일!

- tweedie's formula

  : Sample 들을 통해, data distribution의 진짜 mean을 구하려고 함

  $p(x) \sim N(\mu, \Sigma)$

  $E[\mu | x] = x + \Sigma \nabla_x \log p(x)$

  given data x 에서, $p(x)$가 커지는 방향으로 이동.

☆ - Score based models → 꼭 보고가용

  : 만약 x가 몇개 없으면, $\nabla_x \log q(x)$ 를 어떻게 구할거?

  → $q(x_t) = \int q(x_0)\, q(x_t|x_0)\, dx_0$ (단 $p(x_0) = p(x)$)

  이때 $q(x_t|x_0) \sim N(x_0, \sigma_t^2 I)$ → Gaussian으로 정의

  ⇒ $E\left[\| s_\theta - \nabla_x \log q(x_t|x_0) \|^2\right]$

  → 즉 score를 예측하는 network 만들기

☆ DDIM → DDPM의 Markov 성질을 없애고, forward process의 $\underbrace{\text{marginal distribution}}_{}$을 유지하면서 나머진 자유롭게 (x_0, x_t 의 combination이면 DDPM도 됨)

$q(x_t|x_0)$ //

↳ 그 사이과정인 $q(x_t|x_{t-1})$는 생략도 OK.

- 식 유도.

$$q_\sigma(x_{t-1} | x_t, x_0) = N(w_0 x_0 + w_t x_t + b,\ \sigma_t^2 I)$$ 라고 하자.

$$q_\sigma(x_{t-1} | x_0) = \int \underbrace{q_\sigma(x_t | x_0)}_{} \underbrace{q_\sigma(x_{t-1} | x_t, x_0)}_{\text{위 식}}\, dx_t$$ 이므로

$x_t = \sqrt{\bar{\alpha}_t}\, x_0 + \sqrt{1-\bar{\alpha}_t}\, \epsilon_t$

즉, $N(\sqrt{\bar{\alpha}_t}\, x_0, (1-\bar{\alpha}_t) I)$

$$q_\sigma(x_{t-1} | x_0) = N\left(w_0 x_0 + w_t \sqrt{\bar{\alpha}_t}\, x_0 + b,\ (\sigma_t^2 + w_t^2(1-\bar{\alpha}_t)) I\right)$$

$$= N\left(\sqrt{\bar{\alpha}_{t-1}}\, x_0,\ (1-\bar{\alpha}_{t-1}) I\right)$$

b=0 이라면 바로 나옴

→ μ 와 σ 같음을 이용해서 정리하기.

$$\boxed{q_\sigma(\boldsymbol{x}_{t-1}|\boldsymbol{x}_t, \boldsymbol{x}_0) = \mathcal{N}\left(\sqrt{\bar{\alpha}_{t-1}}\boldsymbol{x}_0 + \sqrt{1-\bar{\alpha}_{t-1}-\sigma_t^2} \cdot \frac{\boldsymbol{x}_t - \sqrt{\bar{\alpha}_t}\boldsymbol{x}_0}{\sqrt{1-\bar{\alpha}_t}}, \sigma_t^2 \mathbf{I}\right)}$$

$\varepsilon \sim N(0, I)$

$p(x) = N(\mu, \sigma_1^2 I)$ → $x = \mu + \sigma_1 \varepsilon$

$p(y|x) = N(ax+b, \sigma_2^2 I)$ → $z = ax + b + \sigma_2 \varepsilon$ ⇒ $E[z] = E[ax+b+\sigma_2\varepsilon] = aE[x]+b = a\mu + b$

$Var[z] = Var[ax+b+\sigma_2\varepsilon] = a^2 Var[x] + \sigma_2^2 Var[\varepsilon]$

$= a^2\sigma_1^2 + \sigma_2^2$

→ $p(y) = N(a\mu + b, (\sigma_2^2 + a^2\sigma_1^2) I)$

- 차이 정리.

→ DDPM : $\boxed{q(x_t | x_{t-1})\text{을 정의하고}}$ $q(x_{t-1} | x_t, x_0)$을 유도.

DDIM : $\boxed{q_\sigma(x_{t-1} | x_t, x_0)\text{을 정의하고}}$, $q_\sigma(x_t | x_{t-1})$을 유도.

단, $q_\sigma(x_t | x_0)$은 DDPM과 동일함 (marginal distribution)

DDIM에선, forward 과정이 $x_0 \to x_T$로 간 다음, x_T로부터 x_t를 구함. 그 이유가 바로 $q(x_t | x_{t-1})$이 정의된게 아니라, $q_\sigma(x_{t-1} | x_t, x_0)$이 정의되어 때문!!

1. DDIM $\supseteq$ DDPM
2. DDIM은 $\sigma = 0$을 통해 deterministic 하게 설정 가능
3. noise prediction network는 재학습 가능! 어차피 $\hat{\epsilon}_\theta(x_t, t)$ 모두 같은 예측이므로...

✓ Classifier Guidance / Classifier free Guidance.

- Classifier Guidance
  - goal : $p(x_t, y)$ ← class
  - score function

$$\nabla_{x_t} \log p(x_t, y) = \nabla_{x_t} \log p(y | x_t) + \underbrace{\nabla_{x_t} \log p(x_t)}_{= -\frac{\epsilon_t}{\sqrt{1-\bar{\alpha}_t}}}$$

from $p(x_t) = N(\sqrt{\bar{\alpha}_t} x_0, (1-\bar{\alpha}_t)I)$

by classification network.

$$\xrightarrow[\text{noise 관점}]{\text{score 관점 말고}} \quad \hat{\epsilon}_\theta(x_t, y, t) = \hat{\epsilon}_\theta(x_t, t) - w\sqrt{1-\bar{\alpha}_t}\, \nabla_{x_t} \log p_\phi(y | x_t)$$

$$\vdots$$

$$= -\sqrt{1-\bar{\alpha}_t}\, \nabla_{x_t} \log\left(p_\theta(x_t)\, p_\phi(y | x_t)^w\right)$$

- Classifier free guidance

실제 구현에서는 λ 대신 $(1+w)$ 사용

  - noise perspective

$$\hat{\epsilon}_\theta(x_t, y, t) = \lambda\, \hat{\epsilon}_\theta(x_t, y, t) + (1-\lambda)\, \hat{\epsilon}_\theta(x_t, \phi, t)$$

$$\vdots$$

$$= -\sqrt{1-\bar{\alpha}_t}\, \nabla_{x_t} \log\left(p(x_t) \left(\frac{p(x_t | y)}{p(x_t)}\right)^\lambda\right)$$

$$\propto -\sqrt{1-\bar{\alpha}_t}\, \nabla_{x_t} \log\left(p(x_t)\, p(y | x_t)^\lambda\right)$$

결국 생각해보면 동일함!

✱ Controlnet & LORA

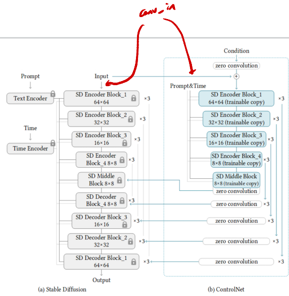

- Controlnet : input 과 condition이 모두 img인 경우.
  - method.
    1. 기본 모델은 freeze, 똑같은 모듈 하나 더 생성하고, 이건 trainable 하게 설정
    2. Condition을 zero conv를 거쳐, input과 합
    3. Encoder layer의 결과를 zero conv를 거쳐 기존 model의 결과와 합
       ↳ literally 더하기.
  - zero conv : 1x1 conv with 모든 params 0 시작

- LORA : low rank adaptation fine tuning 기법
  - 기존 : $x^{1\times d} \cdot W^{d\times d} = h^{1\times d}$
  - lora : $x^{1\times d} \cdot W_1^{d\times 1} \cdot W_2^{1\times d} = h^{1\times d}$

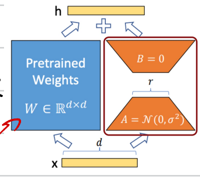

✱ Zero shot Application

1. SDEdit ; user의 그림을 기반으로 현실적 이미지 생성

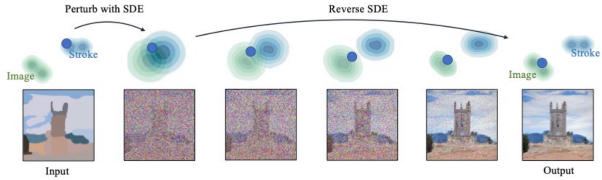

2. Repaint ; user가 없애고 싶은 부분을 자연스럽게 제거